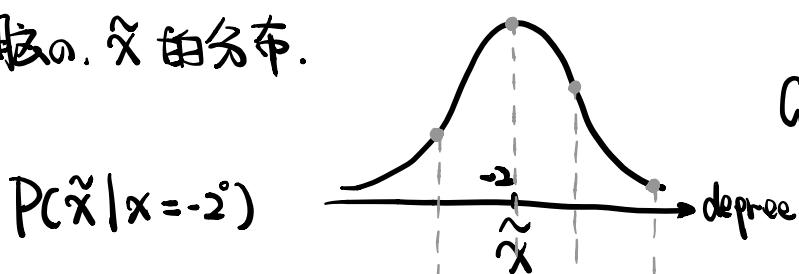


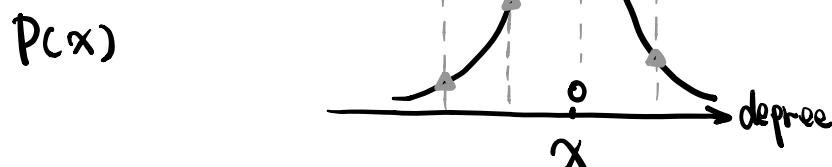
Likelihood 在这 tutorial 中，究竟是什么？

我理解的 Likelihood 是 给定一个真实刺激 X , Subject 对觉系统感受到的真正输入大脑的 \tilde{x} 的分布。



Given a specific stimuli $X = -2^\circ$

但，如果是这样， $P(\tilde{x} | x)$ 是无法与 $P(x)$ 进行 tutorial 中的 pointwise multiplication 来得到后验 $P(x | \tilde{x})$ 分布的。



因为 $P(\tilde{x} | x = -2^\circ)$ 是针对一个真实刺激，而 $P(x)$ 是对真实刺激在每个位置的先验估计。

两者对不上号。再说，即使真求出了一个后验 $P(x|\tilde{x})$ ，这一个对 x 真实位置估计的分布是针对哪个特定的 \tilde{x} ？不要忘了你认为 $P(\tilde{x}|x=-2^\circ)$ 中 \tilde{x} 是个分布啊！

所以说，likelihood 并不是我理解的那样。

那如何理解？

我们先从“离散”的角度来考虑问题，假设听觉刺激只能出现在 $-2^\circ, 0^\circ, 2^\circ$ 这三个位置。由于视觉 cue 出现在 0° ，所以 subject 认为声音刺激大概率出现在 0° 。即 prior $p(x)$ 为，

x	-2°	0°	2°
$p(x)$	$\frac{1}{6}$	$\frac{2}{3}$	$\frac{1}{6}$

当实验室给出一个真实的声音激励 x ，从而有一个通过听觉系统传入大脑的、**确定的** 激励 $\tilde{x} = -2^\circ$ ，基于 \tilde{x} 、prior，subject 得出对真实位置的后验估计**固定了！！**

x	-2°	0°	2°
$P(x \tilde{x}=-2^\circ)$?	?	?

问题是，采在 $P(x)$ 、 $P(x|\tilde{x}=-2^\circ)$ 中闻的是什么？

x	-2°	0°	2°
$P(\tilde{x}=-2^\circ x)$			

标记：当真实激励取不同值时，大脑感知的输入为 $\tilde{x} = -2^\circ$ （一个特定情况）的概率。

\tilde{x}	-2°	0°	2°
x			
-2°	45 次	11	5
0°	10	60	8
2°	2	18	33

$P(\tilde{x}=-2^\circ|x=-2^\circ) = \frac{45}{61} = 0.74$
 $P(\tilde{x}=-2^\circ|x=0^\circ) = \frac{10}{78} = 0.13$
 $P(\tilde{x}=-2^\circ|x=2^\circ) = \frac{2}{53} = 0.04$

以下，整个计算流程为：

Prior:	X	-2°	0°	2°
	$p(x)$	$\frac{1}{6}$	$\frac{2}{3}$	$\frac{1}{6}$
Likelihood: $P(\tilde{x} = -2^\circ x)$		0.74	0.13	0.04
		↓	↓	↓
Posterior: $P(x \tilde{x} = -2^\circ)$		0.12	0.09	0.007

Pointwise multiplication

normalization

综上，明确一下 likelihood 反算流程：

反算流程：

听觉刺激 音觉 cue



-2°

0°

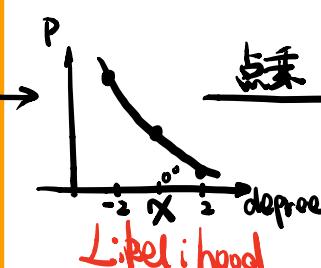
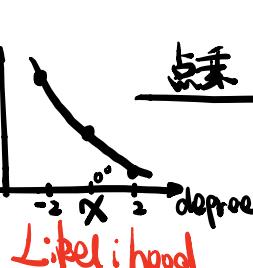
degree



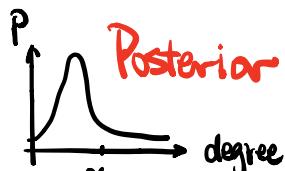
reliable



Prior
 $p(x)$



Bayes Rule



Posterior

$P(x | \tilde{x} = -2^\circ)$

$x \rightarrow \tilde{x}$
noisy
sensory unit

$\tilde{x} = -2^\circ$
大脑实际接收到
(感受引)的激励
输入. 实验者不可知.

真实激励. 实验员
可知. 而 subject 不
可知.

在一个 trial 中，一定
会有一个固定的 \tilde{x} ！

而 likelihood $P(\tilde{x} | x)$ 表示 subject 具有以
一个“能力”，即，他知道在不同真实刺激条件
下，他能感受到这个 $\tilde{x} = -2^\circ$ 的概率。

Tutorial 3 的流程，由此，希望可以了解 Bayesian Stats 的概貌

hypothetical_stim \tilde{x} : 假设大脑接收到的输入
 $-8 \sim 8$, 对于每一个 \tilde{x} , 都会有一个 likelihood (-行)
 e.g., 大脑“认为”: 我感受到 $\tilde{x} = -8$, 不同真实激励
 x 会使我感受到 $\tilde{x} = -8$ 的概率.

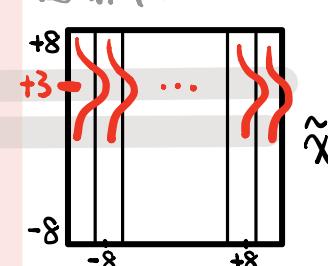
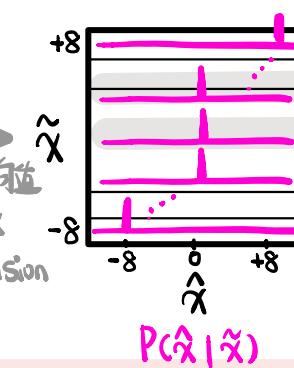
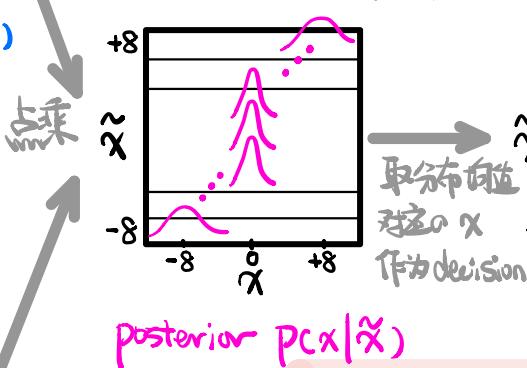
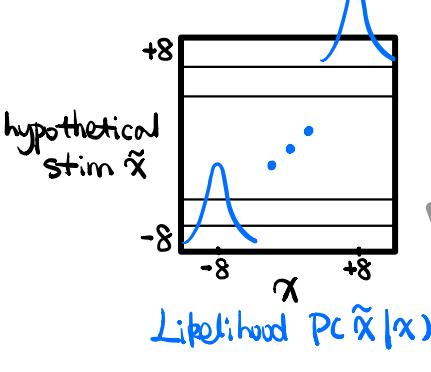
实际问题:

真实激励 $x = +3$

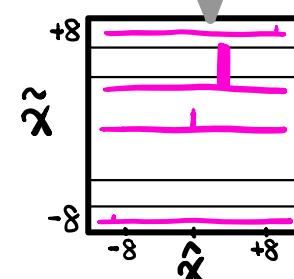
当给出一个真实声音
 激励 $x = +3$ 时, 大
 脑接收到各种 \tilde{x}
 的概率.

当大脑接收到 \tilde{x} 作为输入时,
 其利用 Likelihood, Prior 得出
 以对真实激励 x 的分布估计

当大脑接收到 \tilde{x} 作为输入时,
 其利用 Likelihood, Prior 对
 真实激励的预测 \hat{x}

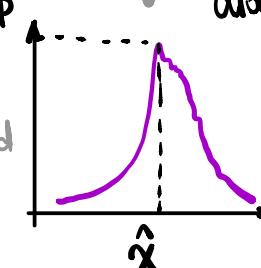


根据在真实激励下, 大脑感
 受各 \tilde{x} 的概率, 来对每个 \tilde{x} ,
 对真实激励的预测 \hat{x} 进行加权

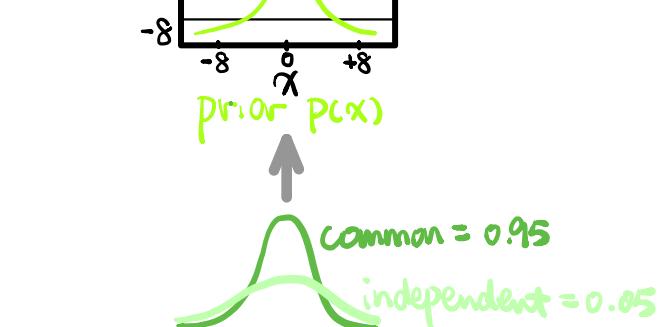


marginalization
along \tilde{x}

当声音激励为 P
 $x = 3$ 时, subject
 基于 prior, likelihood
 对真实位置进行
 预测.



经验概率由两部分认知:



经验概率由两部分认知:

① common: 声音的出现位置与
 表现线索有关

② independent: 两者无关.
 两个经验分布以 P_{common} 为权
 重系数, 进行累加.

这-部分就和是Subject具有的能力一样。

- ① Subject有自己对声音激励位置的先验认知
- ② Subject大脑中，有基于每个刺激的 likelihood
- ③ 大脑中有个贝叶斯过程。
- ④ 估出了基于不同输入的决策分布

当实际给出一个激励时，可以得出对激励位置的估计。

Now that we have generated some data, we will attempt to recover the parameter $p_{independent}$ that was used to generate it.

- 用下图的整个流程，基于特定的 p_{common} or $p_{independent}$ 来生成一个虚拟参与者的数据：(真实激励位置，预测位置)
- 这些组数据是由参与者的先验参数 $p_{independent}$ 决定的。
- 假设参与者的头脑是一个贝叶斯过程，我们能否通过贝叶斯模型，利用参与者的这些行为数据，来估计出这个先验参数？

We have provided you with an incomplete function called `my_Bayes_model_mse()` that needs to be completed to perform the same computations you have performed in the previous exercises

- 就是上述的整个流程

but over all the participant's trial, as opposed to a single trial.

- 但是这次不再是一个 trial 了，而是所有的 trial 一起算。

The likelihood: has already been constructed; since it depends only on the hypothetical stimuli, it will not change.

- 也就是说，在贝叶斯统计中，likelihood 并不是要去优化的。因为遍历了 hypothetical stimuli 就可以知道了。
- 但这对我来说很奇怪，不同人的感知，即likelihood，不应该是不同的吗？

Prior: However, we will have to implement the prior matrix, since it depends on $p_{independent}$. We will therefore have to recompute the posterior, input and the marginal in order to get $p(\hat{x} | x)$.

- $p(\hat{x} | x)$ 是以 $p_{independent}$ 为变量的函数

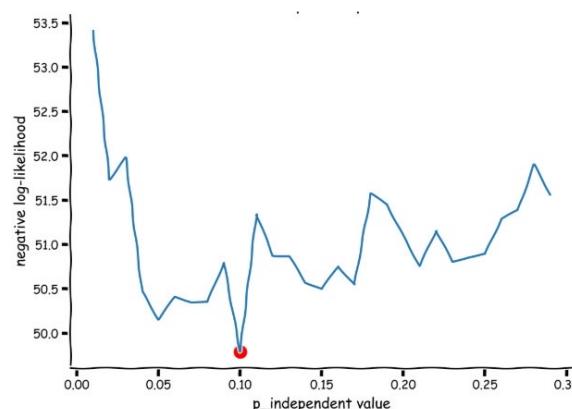
Optimization: Using $p(\hat{x} | x)$, we will then compute the negative log-likelihood for each trial and find the value of $p_{independent}$ that minimizes the negative log-likelihood (i.e. maximises the log-likelihood. See the model fitting tutorial from W1D3 for a refresher).

- 优化出一个 $p_{independent}$ ，使得 LL 最小，即使得贝叶斯模型最能 fit 参与者的行为数据。可见，说了这么多，贝叶斯方法就是在估计参与者的先验知识！！

In this experiment, we assume that trials are independent from one another. This is a common assumption—and it's often even true! It allows us to define negative log-likelihood as:

$$-LL = - \sum_i \log p(\hat{x}_i | x_i)$$

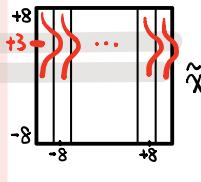
where \hat{x}_i is the participant's response for trial i , with presented stimulus x_i



Input

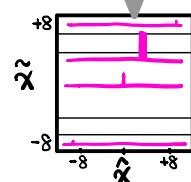
真实声乐 $X = +3$

当给出一个真实声音
声乐 $X = +3$ 时，大
脑会受到各种 \tilde{X}
的输入。



$P(\tilde{X} | X)$

根据在真实声乐下，大脑感
受各种 \tilde{X} 的概率，来对每个 \tilde{X}
对真实声乐的预测进行加权



marginalization
along \tilde{X}

当声乐声乐为 P
 $X = 3$ 时，
基于 prior, likelihood
对真实位置进行
估计。

$\hat{X} = +2.8$

Output

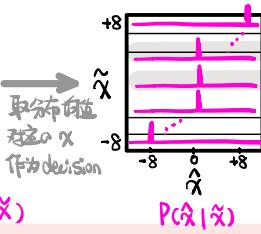
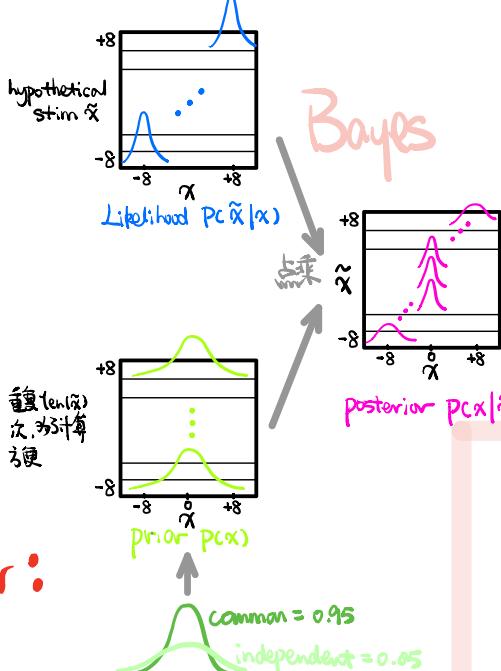
Parameter:

$P_{\text{independent}} = 0.1$

先验概率由两部分认知：

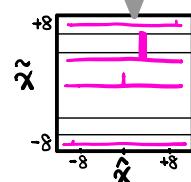
- ① common: 声音的出现位置与
环境线索有关
- ② independent: 两者无关。
两个先验分布以 P_{common} 为权
重累加，进行累加。

common = 0.95
independent = 0.05



$P(\tilde{X}|x)$

根据在真实声乐下，大脑感
受各种 \tilde{X} 的概率，来对每个 \tilde{X}
对真实声乐的预测进行加权



marginalization
along \tilde{X}

当声乐声乐为 P
 $X = 3$ 时，
基于 prior, likelihood
对真实位置进行
估计。

$\hat{X} = +2.8$

Output

Input

真实声源 $x = +3$

当给出一个真实声源
假设 $x = +3$ 时，大脑
会根据各种 \tilde{x}
的样本。

Marginalization

$p(\tilde{x} | \tilde{x})$

$$p(\tilde{x} | x) = \int p(\tilde{x} | x) f(\tilde{x}) d\tilde{x}$$

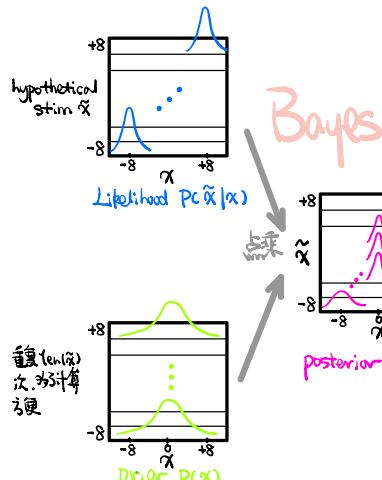
Together with Bayes rule this defines all of Bayesian statistics.

Much of statistics and machine learning is just trying to find good ways of calculating such integrals

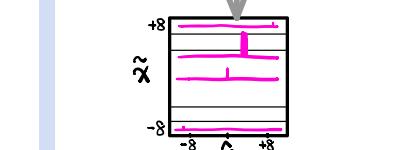
Parameter:

$$P_{\text{independent}} = 0.1$$

- 验证概率由两部分认知：
 ① common：声音的出现位置与
环境线索有关。
 ② independent：两者无关，
两个验证分布以 P_{common} 为权
重系数，进行累加。



根据在真实声源下，大脑感
受名为的样本，来对基名以
对真声源的预测众进行加权



当声源是第 1 时，
 $x = 3$ 时，Subject
基名 prior, likelihood
对真声源进行
预测。

$\hat{x} = +2.8$

Output