

先简单回顾下主成分分析 PCA(principle component analysis) 与奇异值分解 SVD(singular value decomposition)。

一、主成分分析PCA

1、所解决问题

给定 m 个 n 维样本 $X = \{x_0, x_1, \dots, x_m\}$ ，通过变换 $y = Px$ (其中 $P_{k \times n}$ 为变换矩阵)，将样本 $(x_i)_{i=0, \dots, m}$ 从 n 维降到 k 维 $(y_i)_{i=0, \dots, m}$ ，计 $Y = \{y_0, y_1, \dots, y_m\}$ ，同时最大程度的减少降维带来的信息损失。

2、所依赖的原则

根据降维并减小信息损失的目标，可以得出以下两个原则

- 基于标准正交基 $W^T \cdot W = I$ 的投影。
- 降维后的各个维度之间相互独立，即去除降维之前样本 x 中各个维度之间的相关性。
 - 最大程度保持降维后的每个维度数据的多样性，即最大化每个维度内的方差

记降维后样本集 Y 的协方差矩阵为

$$B_{k \times k} = \frac{1}{m} Y Y^T$$

$\frac{1}{m} \cdot \left[\begin{pmatrix} | & | & | \end{pmatrix}_{k \times 1} \begin{pmatrix} | & | & | \end{pmatrix}_{1 \times k} \right] \cdot \left[\begin{pmatrix} | & | & | \end{pmatrix}_{k \times n} \begin{pmatrix} | & | & | \end{pmatrix}_{n \times k} \right] = \begin{bmatrix} \sigma_1^2 & & 0 \\ & \ddots & \\ 0 & & \sigma_k^2 \end{bmatrix}_{k \times k} = B$

上述第一个条件要求协方差矩阵B除了对角线上元素外，其他均为0，也即 B 为对角矩阵。

不同维度的数据之间线性关系正交。

将变换关系 $y = Px$ 代入Y的协方差矩阵B中，

$$B_{k \times k} = \frac{1}{m} Y Y^T = \frac{1}{m} P X (P X)^T = P \frac{1}{m} X X^T P^T = P_{k \times n} C_{n \times n} P_{n \times k}^T \text{ -----(1)}$$

其中， $C_{n \times n} = \frac{1}{m} X X^T$ 是变换前数据 X 的协方差矩阵。

$C_{n \times n}$ 的特征值分解形式如下：

$$D_{n \times n} = Q_{n \times n} C_{n \times n} Q_{n \times n}^T \text{ -----(2)}$$

其中， $D_{n \times n}$ 为对角矩阵。

明显的式(1)和式(2)除了维度不同，其他均一样。

结合上述第二条原则，变换矩阵 $P_{k \times n}$ 即是矩阵C的前k大的特征向量按行组成的矩阵。

3、问题求解方法

式2就是协方差矩阵 C 的特征值分解，变换矩阵 $P_{k \times n}$ 即是矩阵C的前k大的特征向量按行组成的矩阵。所以，PCA的求解步骤为：

- 求 X 均值
- 将 X 减去均值
- 计算协方差矩阵 $C = \frac{1}{m} X X^T$
- 对协方差矩阵 C 特征值分解
- 从大到小排列 C 的特征值
- 取前 k 个特征值对应的特征向量按行组成矩阵即为变换矩阵 $P_{k \times n}$

这里的核心问题是协方差矩阵 $C = \frac{1}{m} X X^T$ 的特征值分解

如果理解了PCA笔记，这一节很好懂，就是对PCA的一种理解方式，其实只看最后一句即可。

二、奇异值分解SVD

1、所解决问题

$$A_{m \times n} = U_{m \times m} \Sigma_{m \times n} V_{n \times n}^T \text{ -----(3)}$$

其中 $U_{m \times m}$ 和 $V_{n \times n}$ 均为正交矩阵， $\Sigma_{m \times n}$ 为对角矩阵

奇异值分解要解决的问题是将 $A_{m \times n}$ 矩阵分解为对角矩阵 $\Sigma_{m \times n}$ ， $\Sigma_{m \times n}$ 中对角元素 σ_i 称为矩阵 $A_{m \times n}$ 的奇异值

2、问题求解方法

$$A^T A = (U \Sigma V^T)^T U \Sigma V^T = V \Sigma^T U^T U \Sigma V^T = V \Sigma^T \Sigma V^T = V \Sigma^2 V^T$$

所以 V 是 $A^T A$ 特征值分解的特征向量按列组成的正交矩阵， Σ^2 是 $A^T A$ 特征值组成的对角矩阵，也可以看出 $A_{m \times n}$ 的奇异值 σ_i 是是 $A^T A$ 特征值 λ_i 的平方根。

$$\sigma_i = \sqrt{\lambda_i} \text{ -----(4)}$$

假如 $A^T A$ 的特征向量为 v_i ，则根据式3和式4， U 中对应的 u_i 则可以由下式求出：

$$u_i = \frac{A v_i}{\sigma_i} \text{ -----(5)}$$

也即奇异值分解的关键在于对 $A^T A$ 进行特征值分解。

如果理解了线性代数笔记中SVD部分，这一节只看这一句就行

三、PCA与SVD的关系

由上述分析可知，

- PCA求解关键在于求解协方差矩阵 $C = \frac{1}{m} X X^T$ 的特征值分解
- SVD关键在于 $A^T A$ 的特征值分解。

很明显二者所解决的问题非常相似，都是对一个实对称矩阵进行特征值分解，

如果取：

$A = \frac{X^T}{\sqrt{m}}$

则有：

$A^T A = \left(\frac{X^T}{\sqrt{m}} \right)^T \frac{X^T}{\sqrt{m}} = \frac{1}{m} X X^T$

→ $\frac{1}{m} X X^T$ 特征值分解 → 取特征值最大的k个特征向量构成PCA变换矩阵 $\begin{pmatrix} | & | & | \end{pmatrix}_{k \times n}$

→ $\frac{X^T}{\sqrt{m}}$ 奇异值分解 → 取 Σ 中最大的k个特征值对应的右奇异矩阵 V 中的k个向量，构成PCA变换矩阵 $\begin{pmatrix} | & | & | \end{pmatrix}_{k \times n}$

SVD与PCA等价，所以PCA问题可以转化为SVD问题求解，那转化为SVD问题有什么好处？

有三点：总的来说，就是降低计算复杂度。

- 一般 X 的维度很高， $A^T A$ 的计算量很大
- 方阵的特征值分解计算效率不高
- SVD除了特征值分解这种求解方式外，还有更高效且更准确的迭代求解法，避免了 $A^T A$ 的计算

其实，PCA只与SVD的右奇异向量的压缩效果相同。如公式图所示，即 $V_{n \times n}^T = \begin{pmatrix} | & | & | \end{pmatrix}_{n \times n}$

- 如果取 V 的前 k 行作为变换矩阵 $P_{k \times n}$ ，则 $Y_{k \times m} = P_{k \times n} X_{n \times m}$ ，起到压缩行即降维的效果
- 如果取 U 的前 d 行作为变换矩阵 $P_{d \times m}$ ，则 $Y_{n \times d} = X_{n \times m} P_{m \times d}$ ，起到压缩列即去除冗余样本的效果。这不是PCA干的。